

NLSY97: образование, заработок и занятость

Распределения, необычные наблюдения
и восстановление пропусков

Коротчик Ярослав Юрьевич, группа 316
Первый этап технологического практикума, 2026-2027

7 423 участника · 14 волн опроса
228 месяцев истории занятости

Один источник: NLSY97

Табличный срез, панель доходов и временной ряд одной когорты


Представление	Наблюдение	Период	Содержание
Таблица	Человек, 7 423 участника	Волна 2011	Заработок за 2010 год, образование, рост, масса, сон
Панель	Человек и волна	14 волн 2004-2023	Заработок за предыдущий календарный год
Временной ряд	Месяц, 228 точек	2004-2022	Доля работающих на неделе 15-го числа

Во всех расчётах исходная когорта - участники волны 2011.
Неответы и неизвестные статусы сохраняются как пропуски.

Источник: BLS / NLSY97, публичная выгрузка 1997-2023. Исходные коды и словари лежат в [datasets/](#).

Изменение занятости в одной когорте



Статус на неделе, содержащей 15-е число каждого месяца; без сезонной корректировки



Знаменатель меняется: 6,002-7,264 человек. Это не показатель занятости всего населения США.

Зарплата в повторных опросах


Доходы в номинальных USD; неизвестные годы не восстанавливаются



Полные ответы во всех волнах: 1,910 человек. Рост смешивает взросление, инфляцию и изменение состава ответивших.

Ядерная оценка: выбор ширины окна


Положительные суммы заработка, три окна вокруг правила Scott



Нулевые заработки: 22.6% известных сумм, учитываются отдельно. При возврате из log нужен множитель $1/x$.

Заработок при заданном образовании



Условные плотности внутри групп, только положительные суммы



У каждой кривой площадь 1. Связь в наблюдательных данных не устанавливает причинный эффект образования.

Размах и отдельные точки дополняют плотность

Слева показаны четыре группы, справа все известные значения роста



Точка вне усов или далеко от группы требует проверки. Автоматического удаления нет.


Шесть методов отвечают на разные вопросы

Метод	Что измеряет	Ограничение
Grubbs	Максимальное отклонение / SD	Нормальное iid-ядро, один экстремум
Dixon r10	Крайний зазор / размах	Малое n, обе стороны в MC-калибровке
IQR	Выход за 1.5 IQR	Правило маркировки, чувствительно к форме
Z	Расстояние в единицах SD	Среднее и SD чувствительны к хвостам
Isolation Forest	Лёгкость изоляции	Зависит от выбранных признаков
LOF	Относительная локальная плотность	Зависит от масштаба и числа соседей

Здесь нет размеченной истины аномалий. Доля пометок не является ассигасу или уровнем значимости.

Какие записи выделили IF и LOF

Полных строк: 6555. Пять признаков, одна выборка для обоих алгоритмов



IF: 1363 пометок. LOF: 136. Совпали: 121.

Grubbs: $G=16.00 > 4.34$. Dixon на $n=20$: $p=0.354$. Выводы условны относительно нормального эталона.

Проверка качества заполнения пропусков

Одинаковые разбиение и маски для всех четырёх методов

01 Разделение людей по кластерам опроса на train и test

02 Соккрытие известных значений: MCAR 10/30% и MAR-like 30%



03 Scaler и импутер обучаются только на повреждённом train

04 MAE и RMSE только в скрытых ячейках test, пять масок

Настоящие ответы не имеют известной истины. Сантиметры и доллары оцениваются раздельно.

Сложный метод помогает не каждому признаку

MCAR 30%, фиксированный split, среднее и SD по пяти маскам



Для сна наименьший RMSE у Mean: 1.36 часа. Рейтинг относится к этому эксперименту.

Восстановление пропусков во времени

Доля работающих во всей когорте: RMSE в процентных пунктах



Метод	Случайный блок 6 мес.	Март-август 2020
Median	1.900	1.100
Forward fill	0.807	3.805
Linear (time)	0.458	2.511

Восстановление истории допускает известные значения справа от пробела.
Для прогноза будущего такой протокол не подходит.

Слева средний RMSE десяти масок. Справа отдельный стресс-тест. Оцениваются только искусственно скрытые значения.

Q-Q и огибающие нормального эталона

Огибающие iid-нормального эталона, параметры переоцениваются в каждой реплике



Точечные 95% относятся к одному рангу; одновременные к целой кривой. Дизайн и округление ограничивают калибровку.

Пять тестов требуют проверки предпосылок



Рост мужчин: $n=3643$. Положительный log-заработок: явная подвыборка $n=5000$

Метод	Рост мужчин	log-заработок
Lilliefors	≤ 0.001 (таблица)	≤ 0.001 (таблица)
Shapiro-Wilk	$5.7e-48$	$3.6e-55$
Shapiro-Francia	$2.7e-45$	$7.6e-53$
Anderson-Darling	0.0002 (MC)	0.0002 (MC)
Cramér-von Mises	0.0002 (MC)	0.0002 (MC)

$p=0.0002$ соответствует пределу MC-разрешения при $B=4999$. На анкетах это iid-ориентир, а не вывод о населении.

Объём выборки и чувствительность теста

Контролируемые iid-выборки, 1000 повторов для каждого закона и n



Показаны три из пяти тестов. Все пять и интервалы Wilson есть в ноутбуке. Неотклонение H_0 не доказывает нормальность.

Результаты и границы выводов

- 01 Один источник даёт таблицу людей и наблюдения во времени
- 02 Доходы содержат нули и обработанный верхний хвост
- 03 Пометка выброса служит поводом проверить исходную запись
- 04 Выбор импутера зависит от признака, метрики и механизма пропусков
- 05 Зависимость и дизайн данных определяют применимость критериев

Все шесть пунктов stage1 выполнены в ноутбуке. Источники, код, таблицы и seed входят в комплект.